

RESUMO EXECUTIVO: ANÁLISE PREDITIVA DE RISCO DE CRÉDITO

Estudante: Raphael Ferreira Vieira

Dataset Analisado: `credit_risk_dataset.csv` (32.581 registros, 12 colunas)

1. Visão Geral do Negócio e Objetivos

O objetivo deste projeto é desenvolver um modelo de inteligência artificial capaz de prever a **inadimplência de clientes (variável `loan_status`)** no momento da solicitação de um empréstimo. No setor bancário, a assertividade nessa classificação é importante pois aprova um crédito para um cliente que ficara inadimplente gera prejuízo ao banco pois ele não recebe o dinheiro além de necessitar de gastos do banco para realizar ações de cobrança administrativa ou judicial. De igual forma não aprovar o financiamento de um bom pagador pode levar também a prejuízo pois nesse caso não emprestando o dinheiro o banco não obtém lucro dos juros e spreads bancários. Esta análise avalia o desempenho competitivo entre dois algoritmos populares: **Árvore de Decisão** e **KNN (K-Vizinhos Próximos)** tendo por objetivo aprender um padrão que maximize a identificação de inadimplentes e garanta que o banco não se prejudique negando crédito a pessoas que porventura pagariam em dia.

1.1 Base de dados:

A observação da base de dados revela as seguintes colunas:

person_age (Idade): Idade do cliente em anos;

person_income (Rendimento Anual): Rendimento anual bruto do cliente por ano;

person_home_ownership (Situação Habitacional): Tipo de posse de habitação do proponente, dividida em quatro categorias: RENT (Arrendado), MORTGAGE (Hipoteca/Crédito habitação), OWN (Casa própria) e OTHER (Outro);

person_emp_length (Tempo de Emprego): Tempo de serviço ou experiência de trabalho do cliente em anos;

loan_intent (Finalidade do Empréstimo): O motivo do pedido do empréstimo, classificado em seis categorias: Pessoal, Educação, Saúde, Negócios/Empreendedorismo, Obras/Remodelação e Consolidação de dívida;

loan_grade (Classificação do Empréstimo): Categoria de risco atribuída ao crédito pelo sistema de scoring, numa escala de A (menor risco) a G (maior risco);

loan_amnt (Montante do Empréstimo): Valor total do empréstimo solicitado pelo cliente em unidades monetárias;

loan_int_rate (Taxa de Juro): Taxa de juro anual do empréstimo em percentagem;

loan_percent_income: Proporção do valor do empréstimo em relação ao rendimento anual do cliente;


cb_person_default_on_file: Indica se o cliente tem um histórico prévio de não cumprimento/falha de pagamento;

cb_person_cred_hist_length: Anos de histórico de crédito registados no bureau desde a abertura da primeira conta/crédito do cliente, variando entre 2 e 30 anos.

2. Principais Insights da Análise Exploratória (EDA)

A análise estatística da base de dados revelou alguns pontos que necessitaram ser tratados antes mesmos de serem imputados ao modelo de Machine Learning.

1. **Desbalanceamento de Classes:** Observou-se que cerca de 80% dos clientes são adimplentes enquanto 20% inadimplentes. Isso cria um desbalanceamento entre classes que se não tratado poderia implicar em alta acurácia, ou seja, percentual alto de acertos no teste, no entanto ignorando a classe minoritária, ou seja não identificando aqueles que seriam inadimplentes. Como o grande volume de dados seria de adimplente, o modelo tenderia a enxergar que todos ou quase todos seriam adimplentes.




- **Linhas duplicadas:** Foram encontradas 165 linhas duplicadas que foram retiradas da base de dados.
- **Outliers Extremos:**
 - A distribuição de idade apresentou registros impossíveis ou improváveis como pessoas com mais de 100 anos.
 - A distribuição de renda anual foi drasticamente distorcida por um *outlier* de altíssimo valor,
 - As colunas `loan_int_rate` e `person_emp_length` apresentaram volumes significativos de dados nulos (ausentes), exigindo tratamento por imputação via mediana para não reduzir o volume amostral da base.
 - Foram encontrados dados que apresentavam a idade do indivíduo menor que o tempo de trabalho necessitando ser retirados da base de dados.

Para as colunas:


- `person_income`: Os outliers serão mantidos, pois a coluna representa o rendimento anual bruto do cliente, salvo a renda anual máxima, que chega a US\$ 6.000.000,00 e terá esse registro discrepante excluído.

- **person_emp_length:** A coluna apresenta valores maiores que 120 anos, o que é fisicamente impossível, podendo estar relacionado a uma inserção incorreta de dados. Os dados serão considerados até 35 anos.
 - **loan_amnt:** Correspondendo ao valor total do empréstimo, constata-se que o dado é fisicamente possível, mesmo aparecendo como um outlier.
 - **loan_int_rate:** Para a taxa de juros anual, embora o gráfico indique a presença de outliers, estes serão mantidos por serem valores fisicamente possíveis.
 - **loan_percent_income:** Representando a proporção do empréstimo em relação ao rendimento anual do cliente, os outliers também serão mantidos, pois a situação pode ocorrer na realidade.
 - **cb_person_cred_hist_length:** Os anos do histórico de crédito também serão mantidos.
 - **person_age:** Apresenta valores pouco coerentes para a idade de um cliente ativo.
- **Valores nulos:** Cerca de 9,6 % dos dados de taxa de juros e 2,7% da coluna **person_emp_length** se encontram com valores nulos e foram tratados.


Para a coluna **person_emp_length** optara-se por atribuir a mediana por idade (**age_person**) para se ter dados mais coerentes com a idade demonstrada nos dados. A mediana global dos dados é de 4. Se por exemplo esse dado fosse imputado para um indivíduo de 18 anos seria considerado que esse indivíduo começou a trabalhar com 14 anos, o que não é lógico. No entanto, observou-se que esse dado não é muito confiável visto que se esperava um comportamento de crescimento do mesmo com o aumento da idade do indivíduo.



Mesmo ocorrendo o preenchimento desse dado, observou-se que o coeficiente de correlação de Pearson com a variável target apresenta quase nenhuma correlação implicando em menos peso para a previsão da variável target. O gráfico abaixo ilustra a correlação entre as variáveis antes da imputação dos valores nulos revelando a pouca correlação dessa variável com a que se deseja prever.




Para a coluna `loan_int_rate`, a taxa de juro está diretamente relacionada com a nota de risco/classificação do empréstimo. Ou seja, quanto maior o risco maior a taxa de juros. Nesse sentido será imputado a mediana dos dados por nota de risco.



Correlação entre variáveis:

- **O Indicador de Maior Risco (loan_percent_income | Correlação: +0.38):** O comprometimento de renda demonstrou ser o fator mais agressivo para a inadimplência. Quanto maior a proporção do valor solicitado em relação ao salário anual do cliente, maior a probabilidade de falha no pagamento.
- **A Pressão dos Juros (loan_int_rate | Correlação: +0.34):** Taxas de juros elevadas estão fortemente atreladas ao não pagamento. Isso evidencia um ciclo operacional de risco: clientes de menor score recebem taxas maiores para compensar o risco, mas o próprio custo do crédito sufoca sua capacidade financeira.




2. Resumo da preparação dos dados

Para garantir o desempenho dos 2 algoritmos que serao empregados posteriormente tratou-se das seguintes fases:

1. **Limpeza:** Eliminação de inconsistências (idades (>100) anos e tempo de emprego maior que a própria idade) e tempo de emprego maior que 35 anos.
2. **Imputação:** Preenchimento de dados nulos usando a **mediana de grupos**, mitigando o efeito dos outliers.
3. **Remoção de duplicadas:** Remoção de registros duplicados para evitar vazamento de dados (*data leakage*).
4. **Codificação:** Transformação de variáveis categóricas em numéricas via *One-Hot Encoding transformacao de variaveis nominais*.
5. **Balanceamento Dinâmico:** Aplicação da técnica **SMOTE** (Synthetic Minority Over-sampling Technique) na base de treino, gerando dados sintéticos da classe inadimplente para equilibrar o aprendizado dos algoritmos.

4. Veredito e Escolha do Melhor Modelo

Após submeter os dados tratados e balanceados aos dois classificadores em análise, a **Árvore de Decisão (Decision Tree Classifier)** apresentou melhores indicadores para a predição ora aqui analisada do que o KNN (K-Vizinhos Próximos).




Justificativa Técnica da Decisão:

Comparando os 2 modelos que tiveram melhor desempenho (Árvore de decisão com $n=5$ e KNN com $k=27$). Como o objetivo é evitar o risco de calote, serão olhadas as métricas da classe 1 ou seja a classe Inadimplente.

- Superioridade no Recall e na Precisão:** A *Árvore de Decisão* superou o KNN em todas as métricas cruciais para o problema de dados desbalanceados e para a classe inadimplente. Ela obteve um bom Recall (**0,68**), o que significa que foi muito mais eficiente em capturar os clientes inadimplentes reais e evitar que o banco aprove créditos de alto risco (Falsos Negativos).
- Menos Alarmes Falsos (Maior Precisão):** O KNN registrou uma precisão de inferior para a variável 1 (0,68) ao modelo de árvore (0,74), indicando que o modelo em árvore

e mais eficiente em não prever um volume excessivo de Falsos Positivos (reprovar bons pagadores por engano) protegendo a receita e a carteira de clientes.

3. **Incompatibilidade do KNN com One-Hot Encoding:** O algoritmo KNN baseia-se em cálculos de distância geométrica (como a distância Euclidiana). Quando transformamos variáveis categóricas textuais em colunas binárias de 0 e 1 (via One-Hot Encoding), as métricas de distância perdem a eficiência matemática natural. A *Árvore de Decisão*, por sua vez, lida de forma nativa e excelente com variáveis numéricas e binárias mistas, criando regras lógicas claras (ex: "Se o comprometimento de renda for maior que X e o cliente mora de aluguel, o risco aumenta").
4. **Simplicidade:** A árvore de decisão apresenta maior simplicidade para a apresentação para a alta direção pois não trabalha com distancias euclidianas multidimensionais. A árvore pode ser explicada por meio de um fluxograma.



Dessa forma para essa condição estudada o modelo Árvore de decisão com profundidade 5 e melhor que o modelo KNN para prever a classe de inadimplência resguardando também o banco em relação aos falsos positivos.

Maior impacto financeiro

O maior impacto financeiro ocorre no falso negativo (Inadimplente previsto como adimplente). Nesse caso o modelo aprova o empréstimo para um cliente que, na realidade, não vai pagar gerando custos posteriores para ações de cobranças e ajuizamentos. Nesse caso o banco tem dificuldade em receber o capital e além disso tem que efetuar gastos para cobrar.

Já o Falso Positivo (FP) ocorre quando o modelo prevê que um cliente Adimplente será inadimplente implicando em não disponibilização do crédito ao parceiro. Com isso a instituição deixa de ser remunerada com os juros e taxas de um financiamento real podendo perder o cliente para um concorrente.